



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Программное обеспечение ЭВМ и информационные технологии

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №6 **«ОБРАБОТКА ДЕРЕВЬЕВ, ХЕШ-ФУНКЦИЙ»**

Студент Козлова Ирина Васильевна

Группа ИУ7 – 32Б

Оглавление

<u>ЦЕЛЬ РАБОТЫ.....</u>	<u>3</u>
<u>ОПИСАНИЕ УСЛОВИЯ ЗАДАЧИ.....</u>	<u>3</u>
<u>ОПИСАНИЕ СТРУКТУРЫ ДАННЫХ.....</u>	<u>5</u>
<u>ОПИСАНИЕ АЛГОРИТМА.....</u>	<u>6</u>
<u>НАБОР ТЕСТОВ.....</u>	<u>6</u>
<u>ОЦЕНКА ЭФФЕКТИВНОСТИ.....</u>	<u>8</u>
<u>ОТВЕТЫ НА КОНТРОЛЬНЫЕ ВОПРОСЫ.....</u>	<u>10</u>
<u>ВЫВОД.....</u>	<u>13</u>

ЦЕЛЬ РАБОТЫ

Цель работы –построить дерево, вывести его на экран в виде дерева, реализовать основные операции работы с деревом: обход дерева, включение, исключение и поиск узлов, сбалансировать дерево, сравнить эффективность алгоритмов сортировки и поиска в зависимости от высоты деревьев и степени их ветвления; построить хеш-таблицу и вывести ее на экран, устранить коллизии, если они достигли указанного предела, выбрав другую хеш-функцию и реструктуризировав таблицу; сравнить эффективность поиска в сбалансированных деревьях, в двоичных деревьях поиска(ДДП), в хеш-таблицах в файлах. Сравнить эффективность реструктуризации таблицы для устранения коллизий и поиска в ней с эффективностью поиска в исходной таблице.

ОПИСАНИЕ УСЛОВИЯ ЗАДАЧИ

Построить ДДП,сбалансированное двоичное дерево (АВЛ) и хеш-таблицу по указанным данным. Сравнить эффективность поиска в ДДП в АВЛ дереве и в хеш-таблице (используя открытую или закрытую адресацию)и в файле. Вывести на экран деревья и хеш-таблицу. Подсчитать среднее количество сравнений для поиска данных в указанных структурах. Произвести реструктуризацию хеш-таблицы, если среднее количество сравнений больше указанного. Оценить эффективность использования этих структур (по времени и памяти) для поставленной задачи. Оценить эффективность поиска в хеш-таблице при различном количестве коллизий.

Описание технического задания

В текстовом файле содержатся целые числа. Построить ДДП из чисел файла. Вывести его на экран в виде дерева. Сбалансировать полученное дерево и вывести его на экран. Построить хеш-таблицу из чисел файла. Использовать закрытое хеширование для устранения коллизий. Осуществить добавление

введенного целого числа, если его там нет, в ДДП, в сбалансированное дерево, в хеш-таблицу и в файл. Сравнить время добавления, объем памяти и количество сравнений при использовании различных (4-х) структур данных. Если количество сравнений в хеш-таблице больше указанного (вводить), то произвести реструктуризацию таблицы, выбрав другую функцию.

Входные данные:

1. **Целое число, представляющее собой номер команды:** целое число в диапазоне от 0 до 6.
2. **Командно-зависимые данные:**
целочисленные значения (количество элемента стека)

Выходные данные:

1. Результат выполнения определенной команды.
2. Сообщение об ошибке.

Функции программы:

1. Загрузить данные из файла.
2. Вывести деревья и хеш-таблицу.
3. Добавить элемент.
4. Вывести сравнение.
5. Рассчитать средние величины.
0. Выход из программы.

Обращение к программе:

Запускается через терминал. Так же можно собрать программу используя makefile, и запустить ее с помощью команды run.

Аварийные ситуации:

1. Некорректный ввод номера команды.
На входе: число, большее чем 6 или меньшее, чем 0.
На выходе: сообщение «ERROR!!! Invalid command entered, please re-enter!!!»
2. Некорректный ввод номера команды.
На входе: пустой ввод.
На выходе: сообщение «Invalid command entered, please re-enter!!!»
3. Некорректный ввод численных значений требуемых программой.
На входе: пустой ввод/буква.
На выходе: сообщение «ERROR!!! Invalid command entered, please re-enter!!!»

4. Некорректный выбор команды.

На входе: команда 2 или 4, без вызова команды 1.

На выходе: сообщение «ERROR!!! Invalid number input! Please choose some command!»

ОПИСАНИЕ СТРУКТУРЫ ДАННЫХ

Структура, описывающая узел дерева.

```
typedef struct node
{
    int data;
    unsigned char height;
    struct node* left;
    struct node* right;
} node_t;
```

Поля структуры

data – данные, хранящиеся в узлах

height – высота дерева в этом узле

***left** – указатель на левую ветку дерева

***right** – указатель на правую ветку дерева

Структура, описывающая данные, которые хранятся в таблице.

```
typedef struct
{
    int flag;
    int value;
} intt;
```

Поля структуры

flag – знак того, что даная ячейка хеш-таблицы занята

value – данные в ячейке хеш-таблицы

Структура, описывающая хеш-таблицу.

```
typedef struct
{
    intt *data;
    int limit;
    int arrsize;
    int sizeall;
} inttable_t;
```

Поля структуры

***data** – указатель на данные
limit – количество коллизий
arrsize – текущий размер хеш-таблицы
sizeall – наибольший размер хеш-таблицы

Хеш — функция:

хеш числа в таблице определяется остатком от деления модуля самого числа на размер таблицы

key – число, len – размер таблицы.

```
int hashh(int key, int len)
{
    return (int)abs(key) % len;
}
```

ОПИСАНИЕ АЛГОРИТМА

1. Выводится меню данной программы.
2. Пользователь вводит номер команды из предложенного меню.
3. Пока пользователь не введет 0 (выход из программы), ему будет предложено вводить номера команд и выполнять действия по выбору.
4. Ре структурирование таблицы производится следующим образом: увеличением размером таблицы в 2 раза. (см приложение 1)

НАБОР ТЕСТОВ

	Название теста	Пользователь вводит	Вывод
1	Некорректный ввод команды	45 (разрешено от 0 до 6)	Invalid command entered, please re-enter!!!
2	Пустой ввод	Пустой ввод.	Invalid command

			entered, please re-enter!!!
3	Команда 1 (неверный ввод номера файла)	5 (разрешено от 1 до 3)	Неверно выбран файл
4	Команда 1 (верный тест)	1 (выбран первый файл)	ДАННЫЕ ЗАГРУЖЕНЫ !
5	Команда 2 (без вызова команды 1)	2 (вызов команды)	ОШИБКА!!! Для начала выберите пункт 1
6	Команда 2 (с вызовом команды 1)	2 (вызов команды)	Деревья (ДДП, АВЛ (СДДП)), хеш- таблица выведены на экран
7	Команда 3 (неверный ввод числа)	А (буква вместо числа)	Ошибка ввода
8	Команда 3 (добавление в пустые деревья и хеш-таблицу)	4 (число, которое надо добавить)	ЧИСЛО УСПЕШНО ДОБАВЛЕНО!
9	Команда 3 (добавление числа в уже существующие деревья и хеш-	4 (число, которое надо добавить, данного числа нет в исходных данных)	ЧИСЛО УСПЕШНО ДОБАВЛЕНО!

	таблицу)		
10	Команда 3 (добавление числа в уже существующие деревья и хеш- таблицу)	4 (число, которое надо добавить, данное число уже есть в исходных данных)	ЧИСЛО УЖЕ ЕСТЬ!!
11	Команда 4 (без вызова команды 1)	4 (вызов команды)	ОШИБКА!!! Для начала выберите пункт 1
12	Команда 4 (с вызова команды 1)	4 (вызов команды)	Успешный вывод
13	Команда 4 (неверное число сравнений)	4 (вызов команды) а (число сравнений)	Ошибка ввода
14	Команда 5 (неверный ввод)	5 (вызов команды) в (кол-во для расчета или число сравнений)	Ошибка ввода
15	Команда 5 (верный ввод)	5 (вызов команды) все данные введены верно	Все верно выводится
16	Команда 6	6	Вывод меню
17	Команда 0	0	Выход из программы

ОЦЕНКА ЭФФЕКТИВНОСТИ

Добавление элемента (в тактах процессора)

в таблице представлены средние величины

Количество элементов	Бинарное дерево	Сбалансированное бинарное дерево	Хеш-таблица	Файл
10	836	987	802	2408
50	1260	1505	1067	2147
100	1386	3402	1012	2611
500	1997	4852	1896	2558
1000	1798	4390	1425	2978

Память (в байтах)

Количество элементов	Бинарное дерево	Сбалансированное бинарное дерево	Хеш-таблица	Файл
10	240	240	104	28
50	1200	1200	424	141
100	2400	2400	824	293
500	12000	12000	4024	1451
1000	24000	24000	8024	2916

Оценка количества сравнение

(среднее значение кол-ва сравнений на данном кол-ве элементов, начинается добавление с пустого дерева(таблицы и файла))

Считаю среднее значение путем вычисления среднего арифметического (сумма всех кол-в сравнения при добавлении всех элементов / на кол-во элементов)

Количество элементов	Бинарное дерево	Сбалансированное бинарное дерево	Хеш-таблица	Файл
10	3	3	2	5
50	5	4	1	24
100	6	5	1	49
500	9	7	1	250
1000	8	5	1	500

Наиболее эффективна хеш-таблица (наименьшее количество сравнений, зависит от выбранной хеш-функции). Сбалансированное дерево эффективнее несбалансированного.

ОТВЕТЫ НА КОНТРОЛЬНЫЕ ВОПРОСЫ

1. Что такое дерево?

Дерево – это нелинейная структура данных, используемая для представления иерархических связей, имеющих отношение «один ко многим». Дерево с базовым типом T определяется рекурсивно либо как пустая структура (пустое дерево), либо как узел типа T с конечным числом древовидных структур этого же типа, называемых поддеревьями.

2. Как выделяется память под представление деревьев?

Способ выделения памяти под деревья определяется способом их представления в программе. С помощью матрицы или списка может быть реализована таблица связей с предками или связный список сыновей.

Целесообразно использовать списки для упрощенной работы с данными, когда элементы требуется добавлять и удалять, т. е. выделять память под каждый элемент отдельно. При реализации матрицей память выделяется

статически.

3. Какие стандартные операции возможны над деревьями?

Основные операции с деревьями: обход дерева, поиск по дереву, включение в дерево, исключение из дерева. Обход вершин дерева можно осуществить следующим образом:

- сверху вниз (префиксный обход)
- слева направо (инфиксный обход)
- снизу вверх (постфиксный обход)

4. Что такое дерево двоичного поиска?

Дерево двоичного поиска – это такое дерево, в котором все левые потомки моложе предка, а все правые – старше.

Это свойство называется характеристическим свойством дерева двоичного поиска и выполняется для любого узла, включая корень. С учетом этого свойства поиск узла в двоичном дереве поиска можно осуществить, двигаясь от корня в левое или правое поддерево в зависимости от значения ключа поддерева.

5. Чем отличается идеально сбалансированное дерево от AVL дерева?

Идеально сбалансированное дерево : при добавлении узлов в дерево мы будем их равномерно располагать слева и справа, то получится дерево, у которого число вершин в левом и правом поддеревьях отличается не более, чем на единицу.

AVL-дерево : двоичное дерево называется сбалансированным, если у каждого узла дерева высота двух поддеревьев отличается не более чем на единицу.

6. Чем отличается поиск в AVL-дереве от поиска в дереве двоичного поиска?

Временная сложность поиска элемента в AVL дереве – $O(\log_2 n)$

Временная сложность поиска элемента в дереве двоичного поиска – от $O(\log_2 n)$ до $O(n)$.

7. Что такое хеш-таблица, каков принцип ее построения?

Массив, заполненный в порядке, определенным хеш-функцией, называется хеш-таблицей. Функцию, по которой можно вычислить этот индекс, называется хеш-функцией. Принято считать, что хорошей является такая функция, которая удовлетворяет следующим условиям:

- функция должна быть простой с вычислительной точки зрения;
- функция должна распределять ключи в хеш-таблице наиболее равномерно.
- функция должна минимизировать число коллизий

8. Что такое коллизии? Каковы методы их устранения.

Коллизия - ситуация, когда разным ключам соответствует одно значение хеш-функции, то есть, когда $h(K1)=h(K2)$, в то время как $K1 \neq K2$.

Первый метод – внешнее (открытое) хеширование (метод цепочек)

В случае, когда элемент таблицы с индексом, который вернула хеш-функция, уже занят, к нему присоединяется связный список. Таким образом, если для нескольких различных значений ключа возвращается одинаковое значение хеш-функции, то по этому адресу находится указатель на связанный список, который содержит все значения.

Второй метод - внутреннее (закрытое) хеширование (открытая адресация).

Оно, состоит в том, чтобы полностью отказаться от ссылок. В этом случае, если ячейка с вычисленным индексом занята, то можно просто

просматривать следующие записи таблицы по порядку (с шагом 1), до тех

пор, пока не будет найден ключ К или пустая позиция в таблице.

9. В каком случае поиск в хеш-таблицах становится неэффективен?

Поиск в хеш-таблицах становится менее эффективен, если наблюдается большое число коллизий. Тогда вместо ожидаемой сложности $O(1)$ получим сложность $O(n)$.

В первом методе - поиск в списке осуществляется простым перебором, так как при грамотном выборе хеш-функции любой из списков оказывается достаточно коротким.

Во втором методе – необходимо просматривать все ячейки, если есть много коллизий.

10. Эффективность поиска в AVL деревьях, в дереве двоичного поиска и в хеш-таблицах

Хеш-таблица - от $O(1)$ до $O(n)$

AVL-дерево - $O(\log_2 n)$

Дерево двоичного поиска – от $O(\log_2 n)$ до $O(n)$.

Вывод

Основным преимуществом деревьев является возможная высокая эффективность реализации основных на ней алгоритмов поиска и сортировки. При удалении или добавлении элемента необходимо корректировать балансировку, тем самым это занимает время.

Хеш-таблицы используют меньше памяти, и для них требуется меньшее количество операций сравнения при добавлении. Так же таблицы требуют качественной хеш-функции, чтобы избежать большого количества коллизий.

Из переведенной выше оценки эффективности можно сделать вывод, что лучше всего и по памяти и по времени работает хеш-таблица. Это объясняется тем, что для того, чтобы в сбалансированное бинарное дерево добавь элемент, необходимо так же сделать балансировку, что занимает время. Так же, когда мы храним данные в таблице, мы не используем указатели, как в случае с деревьями, поэтому память у хеш-таблицы меньше. Так же можно заметить, что сбалансированное дерево не всегда выигрывает у несбалансированного. Проигрывает во времени, так как порядок вершин всегда меняется, но выигрывает в сравнении (по среднему количеству сравнений добавления), так как высота сбалансированного дерева будет меньше или такой же как и у несбалансированного, поэтому чтобы понять куда надо добавить элемент, приходится меньше ходить по дереву.

Приложение 1

Для предложенного мною способа выбора другой хеш-функции и реструктурирования таблицы нашелся пример, который показывает, что данная хеш-функция и ее способы замены не эффективны. Поэтому, проведя некий расчет, я нашла способ улучшить мой алгоритм.

Вместо увеличения размеров таблицы в 2 раза, я увеличиваю ее в 1.2 раза, тем самым при примере

1 11 21 31 41 51 61 71 81 91 111 121 131

Таблица выглядит следующим образом

i	Хэш	Значения
0	0	0
1	1	1
2	2	21
3	3	41
4	4	61
5	5	81
6	0	0
7	7	121
8	0	0
9	0	0
10	0	0
11	11	11
12	12	31
13	13	51
14	14	71
15	15	91
16	16	111
17	17	131
18	0	0

(поле i - идеальное значение хеша, то есть число с таким хешом должно быть записано в данную ячейку, поле Хеш — хеш данного числа)